FAST TRACK IA · TURMA 1 · DESAFIO 1

CredAIR: análise de risco de crédito

Quais propostas têm maior risco de inadimplência, e por quê

Alex Lourenço

Simulador: cred-air-v2.vercel.app · Repositório: github.com/alexlourenc/CredAIR-v2

O problema: prever quem não vai pagar

34,4%

das 5.000 propostas resultaram em inadimplência

Falso negativo: aprovar um mau pagador

A CredAIR perde o capital emprestado. É o erro mais caro.

Falso positivo: recusar um bom pagador

A CredAIR perde os juros e o cliente.

Quem chuta sempre “adimplente” acerta 66% sem aprender nada: a acurácia engana.

Organização: os dados em três camadas

Bronze

O dataset exatamente como recebido. Nunca é alterado, e o hash SHA-256 está registrado.

Prata

Dados limpos: duplicatas removidas, UFs padronizadas, valores inválidos marcados como ausentes.

Ouro

Pronto para o modelo, com a variável derivada criada linha a linha.

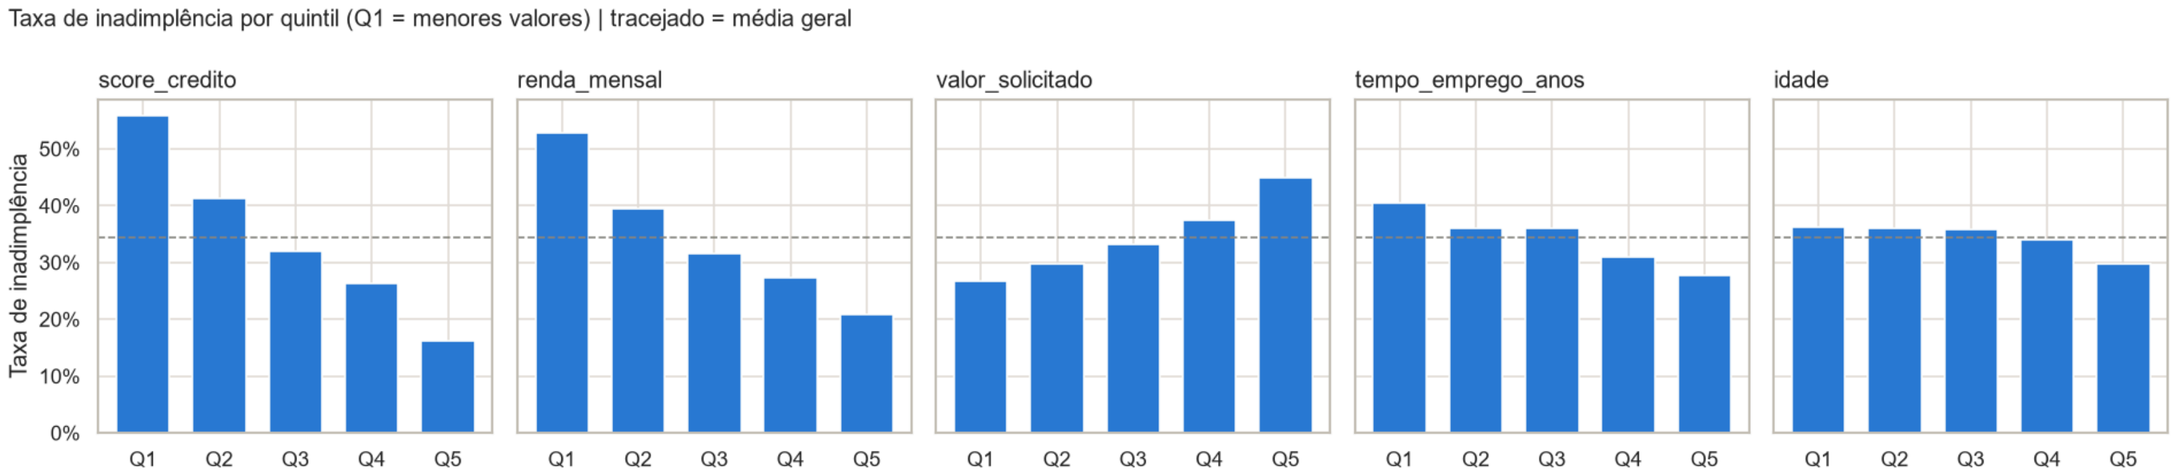
Regra contra vazamento de dados: o que aprende com os dados (mediana, média, desvio) é ajustado só no treino, dentro do Pipeline do scikit-learn.

Qualidade: diagnosticar antes de tratar

Problema encontrado	Registros	Tratamento
Espaços em estado (85 “UFs” → 27)	101	Padronizar
Linhas duplicadas, até nos centavos	19	Remover a cópia
Idade de 210 a 750 anos	15	Marcar como ausente
Tempo de emprego ≥ idade	8	Marcar como ausente
Renda de R$ 100 a R$ 550, de 50 em 50	10	Marcar como ausente
Início de trabalho antes dos 14 anos	~690	Manter e medir o impacto

Marcar como ausente preserva as outras colunas da linha. Dividir a idade por 10 foi testado e descartado: é uma suposição não verificável. A correção do tempo de emprego não muda o modelo (AUC 0,793 contra 0,794).

O que os dados mostram



56% → 16%

Score: do menor para o maior quintil. O sinal mais forte.

53% → 21%

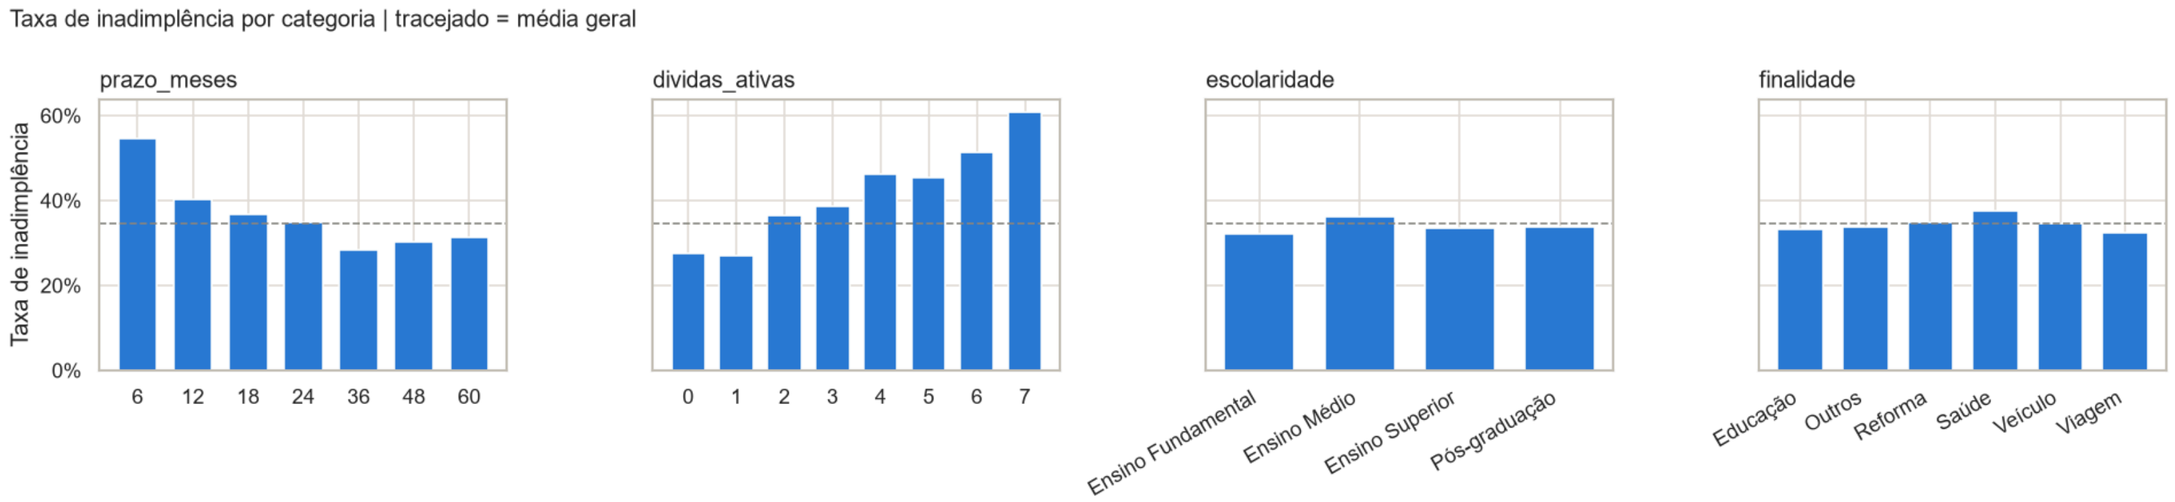
Renda: mais renda, menos inadimplência.

p = 0,60

Estado: 29% a 42% entre UFs, mas compatível com o acaso.

CredAIR · Quintis: 5 faixas com o mesmo número de propostas · tracejado = média geral (34%)

O paradoxo do prazo



54% em 6 meses, 28% em 36

Prazos **curtos** têm mais inadimplência, ao contrário do esperado. Hipótese: o vilão não é o prazo, é a **parcela pesada** que um prazo curto gera.

CredAIR · Dívidas ativas: de 27% (nenhuma) a 61% (sete) · escolaridade e finalidade ficam perto da média

A VARIÁVEL CRIADA

Comprometimento da renda = (valor ÷ prazo) ÷ renda

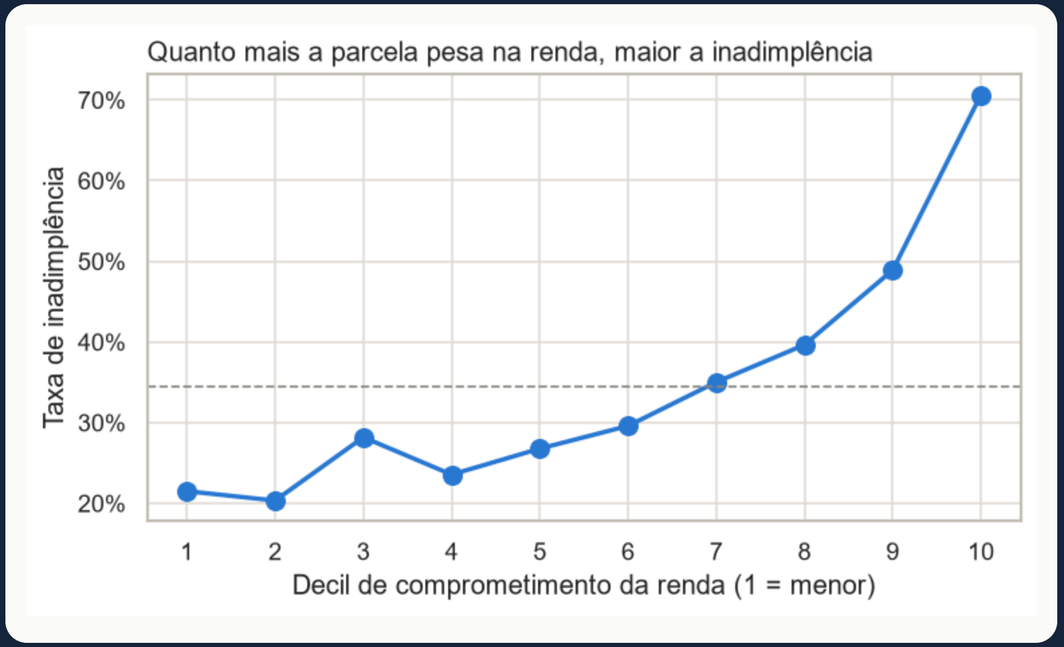
21% → 71%

de inadimplência, do menor para o maior decil

0,769 → 0,793

AUC do modelo na validação cruzada, ao incluí-la

2ª variável mais forte sozinha (AUC 0,667), à frente das três que combina.

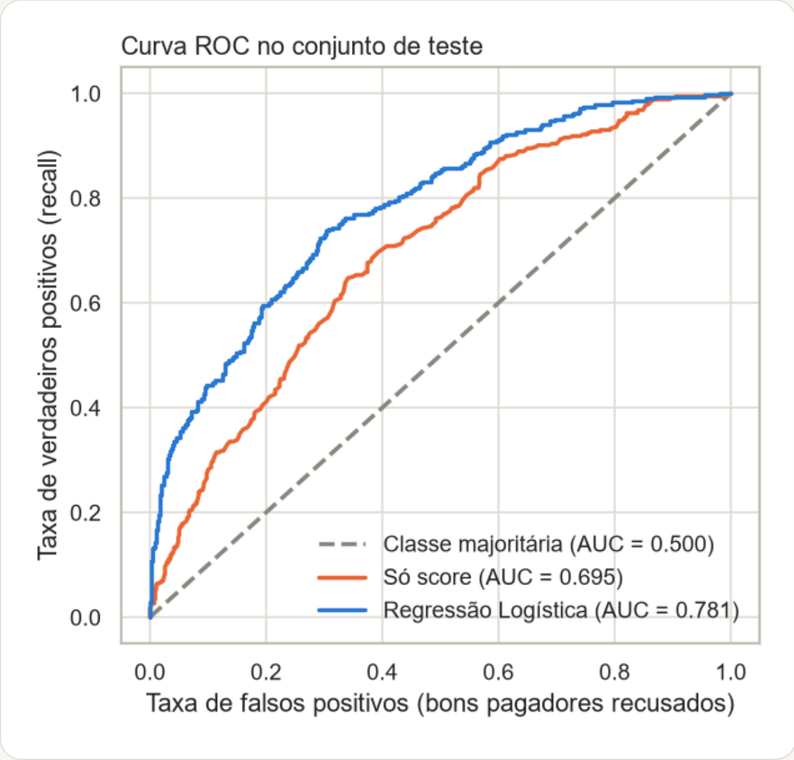


Modelagem: a escolha pela validação cruzada

Configuração (validação cruzada com 5 partes, só no treino)	AUC média
Classe majoritária (referência)	0,500
Só score (referência)	0,679
Regressão logística: variáveis originais	0,769
+ comprometimento da renda	0,793
+ comprometimento + estado	0,788
Só numéricas + comprometimento (modelo final)	**0,794**
Só numéricas, com o tempo de emprego corrigido	0,793

O estado não ajuda e tem risco ético: fica de fora. Escolaridade e finalidade não acrescentam nada: diante do empate, fica o modelo mais simples, com 8 variáveis numéricas.

No teste, o modelo ordena melhor o risco



0,781

AUC da regressão logística no teste

0,695

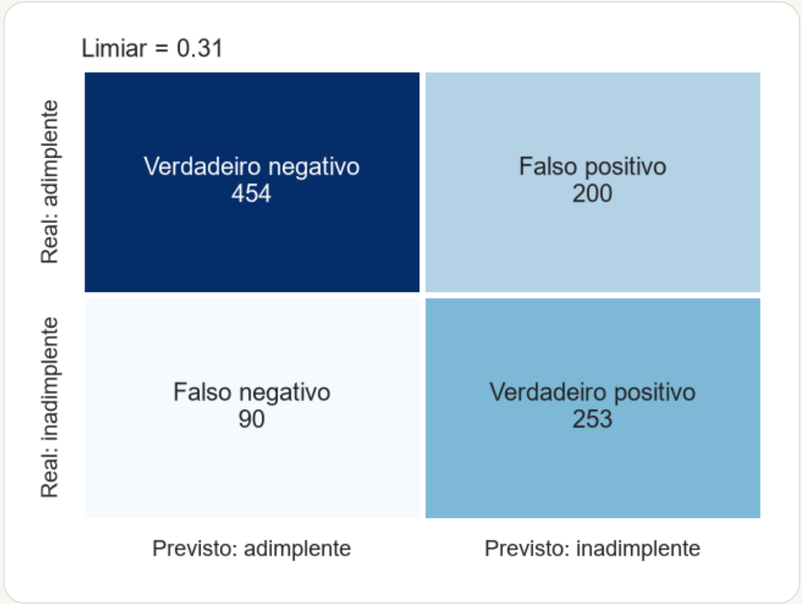
AUC da regra só com o score

Próxima da validação cruzada (0,794): o modelo aprendeu padrões, não decorou o treino.

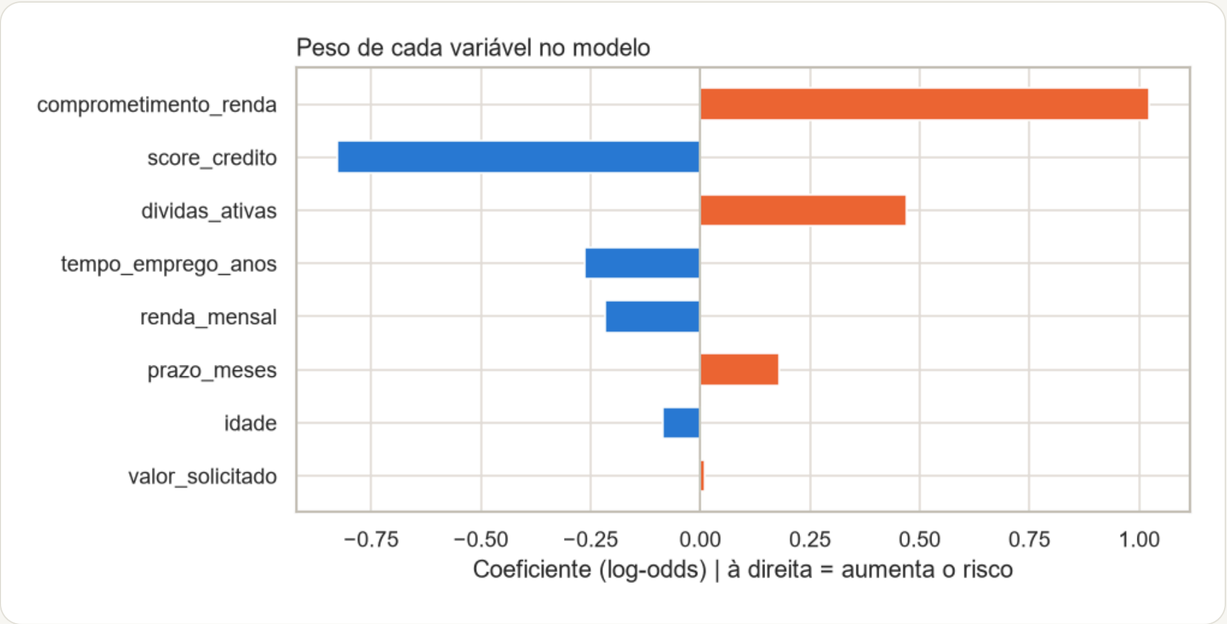
O limiar é uma decisão de negócio

No teste (343 inadimplentes)	Limiar 0,5	Limiar 0,31
Inadimplentes identificados	45%	**74%**
Calotes aprovados	188	**90**
Alertas falsos	74	200
Alertas corretos (precisão)	68%	56%

O limiar de 0,31 foi escolhido no treino (F1 máximo). Para evitar 98 calotes, o modelo dá alerta em 126 bons pagadores a mais: a proposta sinalizada vai para análise, não para recusa automática.



O que mais pesa no risco



Comprometimento da renda ×2,78: o maior fator de risco

Score ×0,44: o maior fator de proteção

Dívidas ativas ×1,60: mais risco

O prazo troca de sinal: descontada a parcela pesada, prazo mais longo aumenta levemente o risco. O vilão nunca foi o prazo.

Do notebook ao produto

Pacote credair

As regras num só lugar, usadas pelo notebook, pelos testes e pelo simulador.

45 testes

Rodam no GitHub Actions a cada push e conferem AUC 0,781 e limiar 0,31.

Simulador no Vercel

Sem scikit-learn: usa os parâmetros exportados e dá a mesma probabilidade.

A mesma proposta: R$ 20 mil em 6 meses, com renda de R$ 3 mil (parcela de 111% da renda)

93%

Modelo final: alto risco

56%

Sem o comprometimento da renda

33%

Só com o score

CredAIR · cred-air-v2.vercel.app · limiar ajustável e comparação entre três versões validadas

Conclusões, limitações e cuidados

Ação prática

- No limite, oferecer prazo maior ou valor menor, em vez de recusar
- Teto de comprometimento: 94% de calote quando a parcela passa da renda
- Revisar o limiar com os custos reais

Limitações

- Dados sintéticos
- Tempo de emprego pouco confiável
- Viés de seleção: só propostas já analisadas
- Parcela estimada sem juros
- Sem dimensão temporal

Cuidados em produção

- Apoio à decisão, não decisão automática
- Justiça e LGPD: nada de estado
- Monitorar o drift e retreinar
- Mesmas regras de limpeza do treino

Obrigado

Perguntas?

Simulador: cred-air-v2.vercel.app

Repositório: github.com/alexlourenc/CredAIR-v2